

Documento Técnico de Referencia: AetherCore v4.5

Manual de Arquitectura, Políticas Operativas y Especificaciones de Evaluación RAG

ID Documento: DOC-RAG-2026-TEST

Versión del Sistema: v4.5.2-Enterprise

Fecha de Emisión: 12 de Agosto de 2026

Clasificación: Confidencial / Test Set

Autor Principal: Dr. Roberto Arlt (Arq. Lead)

Dominio: Cloud & Vector Databases

ÍNDICE DEL DOCUMENTO DE PRUEBA

- Resumen Ejecutivo y Arquitectura General (Módulos principales, Topología y Métricas SLA)
- Parámetros de Configuración y Constantes del Sistema (Vectores, Índices HNSW y Límites)
- Políticas de Retención de Datos, Seguridad y Criptografía (Tiempos de vida, Algoritmos, Protocolos)
- Procedimiento Operativo Estándar (SOP-882): Manejo de Incidentes y Split-Brain
- Matriz de Datos de Evaluación RAG y Casos de Esquina (Fact Sheet)
- Glosario Técnico y Términos Específicos

1. Resumen Ejecutivo y Arquitectura General

La plataforma **AetherCore v4.5** es una infraestructura distribuida de procesamiento vectorial de alta velocidad y orquestación de modelos de lenguaje en tiempo real. Este documento ha sido diseñado específicamente como corpus sintético multicapa para la evaluación, validación y benchmarking de sistemas de *Retrieval-Augmented Generation* (RAG). Contiene datos tabulares, parámetros numéricos de alta precisión, reglas operativas condicionales y entidades ficticias con relaciones complejas.

La arquitectura de AetherCore está fragmentada en cuatro subsistemas independientes que se comunican mediante un bus gRPC con cifrado mTLS habilitado por defecto:

- AetherConnect (Puerto TCP 9091):** Pasarela de entrada de peticiones HTTP/3 y REST API. Administra la autenticación JWT y el rate limiting por token de cliente.
- AetherStore (Puerto TCP 9092):** Base de datos vectorial distribuida basada en un motor HNSW optimizado (*Hesperis-Engine*). Mantiene índices vectoriales de dimensión $D = 1536$ y $D = 3072$.
- AetherCompute (Puerto TCP 9093):** Clúster de GPU (Nvidia H100/A100) dedicado a la inferencia de embeddings y re-ranking dinámico mediante modelos Cross-Encoder.
- AetherGuard (Puerto TCP 9094):** Módulo de gobernanza, auditoría en tiempo real y detección de alucinaciones mediante validación semántica cruzada.

Nota Técnica de Importancia para Sistemas RAG

Para probar la capacidad de extracción exacta: El umbral de tolerancia a la latencia global en el nodo SA-EAST-1 (Región Sao Paulo) es de exactamente **18.4 milisegundos** para el percentil p99, mientras que en la región US-EAST-1 es de **12.1 milisegundos**.

1.1 Resumen de SLAs Operativos por Región

Código de Región	SLA Disponibilidad	Latencia Target (p95)	Capacidad Máxima (QPS)	Contacto Técnico Lead
US-EAST-1 (N. Virginia)	99.99%	8.5 ms	120,000 QPS	Ing. Elena Rostova
EU-WEST-1 (Irlanda)	99.95%	10.2 ms	95,000 QPS	Ing. Lars Lindqvist
SA-EAST-1 (San Pablo)	99.90%	14.0 ms	45,000 QPS	Ing. Carlos Zalazar
AP-SOUTHEAST-2 (Sídney)	99.85%	19.5 ms	30,000 QPS	Ing. Mei-Ling Zhou

2. Parámetros de Configuración y Constantes del Sistema

Para la correcta sintonización del motor vectorial de AetherCore, existen variables globales de entorno que condicionan el comportamiento de la recuperación de documentos y el espacio de búsqueda en grafos. Los valores indicados a continuación corresponden a la versión oficial de producción 4.5.2:

```
# Archivo de Configuración Canónico: /etc/aethercore/aethercore.env
AETHER_ENGINE_VERSION="4.5.2-RELEASE"
AETHER_VECTOR_DIMENSION=1536
AETHER_DISTANCE_METRIC="cosine"           # Opciones: cosine, euclidean, dot_product
AETHER_HNSW_M=32                          # Número de conexiones bidireccionales por nodo
AETHER_HNSW_EF_CONSTRUCTION=200           # Tamaño de la lista dinámica de candidatos
AETHER_HNSW_EF_SEARCH=64                  # Profundidad de búsqueda en tiempo de consulta
AETHER_MAX_BATCH_SIZE=8192                # Tamaño máximo de lote para ingesta paralela
AETHER_SIMILARITY_THRESHOLD=0.8125        # Umbral mínimo para considerar coincidencia válida
AETHER_CACHE_TTL_SECONDS=3600             # Tiempo de vida de la memoria caché de re-ranking
```

La distancia entre dos vectores **u** y **v** dentro del espacio coseno en AetherStore se calcula formalmente mediante la expresión:

$$D_{\{cos\}}(u, v) = 1 - \frac{\sum_{i=1}^n u_i v_i}{\sqrt{\sum_{i=1}^n u_i^2} \sqrt{\sum_{i=1}^n v_i^2}}$$

Donde **n = 1536**. Si la similitud calculada cae por debajo del valor estipulado en `AETHER_SIMILARITY_THRESHOLD` (**0.8125**), la consulta se descarta automáticamente y el sistema retorna un código de estado interno `ERR_4048_LOW_SIMILARITY`.

3. Políticas de Retención de Datos, Seguridad y Criptografía

La retención de datos en AetherCore sigue un esquema tripartito según el tipo de almacenamiento (*Tiering Storage*). Es fundamental que los sistemas de QA diferencien entre los tres niveles para evitar alucinaciones en consultas de cumplimiento normativo:

- 1. **Tier Hot (Memoria RAM NVMe-backed):** Retención por **30 días naturales**. Diseñado para datos de alto acceso y re-ranking inmediato. Todos los datos están encriptados con la clave simétrica rotativa `K-HOT-2026`.
- 2. **Tier Warm (SSD NVMe en clúster):** Retención desde el día 31 hasta los **180 días naturales**. Los datos pasan a un estado de compresión *Zstandard* (nivel de compresión 12).

3. **Tier Cold (Object Storage Glacier):** Retención garantizada por **7 años (2555 días)** para fines de auditoría financiera y legal. La recuperación de un bloque Cold requiere una solicitud firmada con quorum 2 de 3 por los administradores de seguridad.

Regla Crítica de Exclusión (Data Purge)

Bajo ninguna circunstancia se conservarán registros logs de IPs de clientes por más de **14 días hábiles**. La violacion de esta directiva activa el protocolo automático de purga `PURGE_SEC_LEVEL_0` bajo la orden de control ISO-27001-A.12.

3.1 Cifrado en Transito y en Reposo

Todos los volúmenes de datos en reposo emplean el algoritmo **AES-256-GCM** con una clave de 256 bits generada por un HSM (Hardware Security Module) físico modelo *Thales Luna K7*. Las claves se rotan automáticamente cada **90 días** a las 02:00 UTC. Para las comunicaciones en tránsito, solo se aceptan cifrados TLS versión 1.3 con los siguientes suites autorizados:

- `TLS_AES_256_GCM_SHA384`
- `TLS_CHACHA20_POLY1305_SHA256`

4. Procedimiento Operativo Estándar (SOP-882): Manejo de Incidentes

Este procedimiento describe las acciones necesarias ante un evento de incoherencia de estado o desincronización de clúster (*Split-Brain*) en la capa AetherGuard.

4.1 Niveles de Severidad de Incidentes

Nivel	Descripción del Impacto	Tiempo Máximo de Respuesta (SLA)	Responsable de Escalado
P1 - CRÍTICO	Caída total del servicio vectorizador o pérdida de datos activa.	15 minutos	On-Call Incident Commander
P2 - ALTO	Degradación de latencia > 50% o fallo de región secundaria.	45 minutos	Lead DevOps Engineer
P3 - MEDIO	Fallo en tareas de re-ranking secundarias o métricas atípicas.	4 horas	SRE Team Lead
P4 - BAJO	Inconsistencia menor en logs o consulta lenta aislada.	24 horas	Junior Admin / Helpdesk

4.2 Secuencia de Recuperación ante Split-Brain en AetherGuard

Si el córum Raft del clúster pierde más del 50% de los nodos de control, ejecute la siguiente secuencia manual desde el nodo maestro designado:

- Aísle la red del nodo conflictivo ejecutando: `iptables -A INPUT -p tcp --dport 9094 -j DROP`.
- Force la re-elección de líder mediante la bandera de recuperación: `aether-ctl cluster recover --force-leader --node-id=node-01-sa`.
- Verifique la integridad del índice hash con la función de verificación cruzada: `aether-ctl check-integrity --checksum=SHA256`.
- Restablezca el tráfico levantando la regla de firewall previamente impuesta.

5. Matriz de Datos de Evaluación RAG (Fact Sheet)

Esta sección contiene hechos atómicos específicos para validar si el sistema RAG logra recuperar información contextual fina ("needle in a haystack").

Pregunta de Prueba RAG	Respuesta Exacta Esperada	Ubicación en el Texto / Contexto Clave
¿Cuál es el puerto predeterminado de AetherGuard?	Puerto TCP 9094	Sección 1 (Lista de subsistemas)
¿Qué algoritmo de compresión se usa en el Tier Warm?	Zstandard con nivel de compresión 12	Sección 3 (Punto 2)
¿Cada cuántos días se rotan las claves del HSM?	Cada 90 días a las 02:00 UTC	Sección 3.1
¿Cuál es el nombre del modelo HSM utilizado?	Thales Luna K7	Sección 3.1
¿Quién es la responsable técnica de la región US-EAST-1?	Ing. Elena Rostova	Sección 1.1 (Tabla de SLAs)
¿Cuál es el umbral mínimo de similitud configurado?	0.8125 (AETHER_SIMILARITY_THRESHOLD)	Sección 2 (Bloque de código y texto)
¿Cuál es el tiempo de retención máximo para logs de IP?	14 días hábiles	Sección 3 (Regla Crítica de Exclusión)
¿Qué comando se usa para forzar el líder en Split-Brain?	<code>aether-ctl cluster recover --force-leader --node-id=node-01-sa</code>	Sección 4.2 (Paso 2)

6. Glosario Técnico y Términos Específicos

Para probar la desambiguación sintáctica y la capacidad de vocabulario del embedding model, a continuación se definen términos propios del ecosistema AetherCore:

Hesperis-Engine: Motor de búsqueda vectorial propietario desarrollado sobre arquitectura C++20 que utiliza cuantización escalar de 8 bits (SQ8) y compresión de grafos navegables para reducir el consumo de RAM en un 40% respecto a HNSW estándar.

Vector-Drift (Deriva Vectorial): Fenómeno donde el espacio latente sufre una degradación semántica superior al 3.2% debido a cambios progresivos en el vocabulario del modelo de lenguaje emisor sin una re-indexación completa del corpus.

Protocolo ChronoSync: Mecanismo interno de sincronización temporal distribuida con precisión inferior a 5 microsegundos, utilizado para marcar los timestamp de los vectores guardados en AetherStore.

Filtro de Bloom Cuántico (Q-Bloom): Estructura probabilística complementaria alojada en AetherGuard para descartar en tiempo $O(1)$ el 99.8% de las consultas redundantes o con tokens de malicia inyectados antes de consultar el índice principal.

Cuórum Raft-Aether: Variación del algoritmo Raft modificado para tolerar fallos bizantinos leves de hasta un $f = \lfloor \frac{n-1}{3} \rfloor$ nodos en la red de AetherStore.

Fin del Documento de Test RAG

Este documento concluye la serie de datos sintéticos de validación para AetherCore v4.5. Puede agregarse directamente a la base de conocimientos vectorial (vector DB) mediante chunking de tamaño recomendado de **500 a 800 tokens** con un solapamiento (*overlap*) de **100 tokens**.